

# Ćwiczenia laboratoryjne

Akademia Górniczo-Hutnicza im. Stanisława Staszica w Krakowie  
AGH University of Science and Technology

Justyna Tora





# Stacjonarność szeregów czasowych

# Stacjonarność

Szereg czasowy jest stacjonarny jeśli jego podstawowe własności nie zmieniają się w czasie. Wyróżnia się słabą stacjonarność (stacjonarność w szerszym sensie) oraz silną stacjonarność.

Proces jest **słabo stacjonarny** jeśli spełnione są następujące warunki:

- » Wartość oczekiwana procesu stochastycznego  $E(X_t) = \mu$  jest stała i skończona.
- » Wariancja procesu stochastycznego  $var(X_t) = \sigma^2$  jest stała i skończona.
- » Funkcja autokowariancji zależy wyłącznie od opóźnienia:  
 $cov(X_t, X_{t-k}) = \gamma(k)$



# Testy weryfikujące stacjonarność

## ➤ **Test ADF** (augmented Dickey-Fuller test)

Hipoteza zerowa: szereg czasowy nie jest stacjonarny

Hipoteza alternatywna: szereg czasowy jest stacjonarny

Funkcja w R: ***adf.test()*** z pakietu ***tseries***

## ➤ **Test KPSS** (Test Kwiatkowskiego, Phillipsa, Schmidta i Shina)

Hipoteza zerowa: szereg czasowy jest stacjonarny

Hipoteza alternatywna: szereg czasowy nie jest stacjonarny

Funkcja w R: ***kpss.test()*** z pakietu ***tseries***

# Autokorelacja składnika losowego

# Autokorelacja

Jednym z założeń MNK jest brak autokorelacji składnika losowego.

Model:  $y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki} + \varepsilon_i$ , dla  $i = 1, \dots, n$

Macierz wariancji-kowariancji składników losowych (w przypadku spełnionych odpowiednich założeń):

$$D^2(\varepsilon) = \begin{bmatrix} \sigma^2 & 0 & \dots & 0 \\ 0 & \sigma^2 & & 0 \\ & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma^2 \end{bmatrix}$$

Jeśli założenie o braku autokorelacji składnika losowego nie jest spełnione, to macierz wariancji-kowariancji nie jest diagonalna. Wówczas estymator wektora parametrów modelu jest nieefektywny.


# Analiza korelogramu

**Wykres ACF** (Autocorrelation Function) – wykres przedstawiający współczynniki autokorelacji dla kolejnych opóźnień.

Funkcja w R: ***acf()*** z pakietu ***stats***

**Wykres PACF** (Partial Autocorrelation Function) – wykres przedstawiający autokorelacje cząstkowe (bez zależności od elementów pośrednich).

Funkcja w R: ***pacf()*** z pakietu ***stats***





# Testy weryfikujące autokorelację

- Test Durbina-Watsona (tylko do wykrywania autokorelacji I rzędu)  
Funkcja w R: ***dwtest()*** z pakietu ***lmtest***
- Test Breuscha-Godfrey'a  
Funkcja w R: ***bgtest()*** z pakietu ***lmtest***
- Test Ljung-Boxa  
Funkcja w R: ***Box.test(..., type = "Ljung")*** z pakietu ***stats***

Hipoteza zerowa: brak autokorelacji

Hipoteza alternatywna: występuje autokorelacja

# Metoda Cochrane'a-Orcutta

Jeżeli w modelu występuje zjawisko autokorelacji składnika losowego należy skorygować metodę estymacji parametrów lub zmienić postać analityczną modelu.

W przypadku wystąpienia autokorelacji I rzędu:

Krok 1: Szacujemy współczynnik autokorelacji  $\hat{\rho}$

Krok 2: Dokonujemy przekształceń zmiennych zgodnie ze wzorami:

$$\begin{aligned} y_t^* &= y_t - \hat{\rho}y_{t-1} \\ x_{jt}^* &= x_{jt} - \hat{\rho}x_{jt-1}, \quad j = 1, 2, 3, \dots, k \end{aligned}$$

Krok 3: Budujemy model na nowo utworzonych zmiennych.


# Homoskedastyczność składnika losowego

# Homoskedastyczność


Jednym z założeń MNK jest homoskedastyczność składnika losowego (stałość wariancji błędu losowego).

Przeciwieństwem homoskedastyczności jest heteroskedastyczność.

**Homoskedastyczność**



**Heteroskedastyczność**



# Homoskedastyczność

Model:  $y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki} + \varepsilon_i$ , dla  $i = 1, \dots, n$

Macierz wariancji-kowariancji składników losowych:

$$D^2(\varepsilon) = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1n} \\ \sigma_{21} & \sigma_2^2 & & \sigma_{2n} \\ \vdots & & \ddots & \vdots \\ \sigma_{n1} & \sigma_{n2} & \dots & \sigma_n^2 \end{bmatrix}$$

gdzie  $\sigma_i^2 = D^2(\varepsilon_i)$ ,  $\sigma_{ij} = cov(\varepsilon_i, \varepsilon_j) = cov(\varepsilon_j, \varepsilon_i) = \sigma_{ji}$

**Założenie homoskedastyczności składników losowych:**

$$\sigma_1^2 = \sigma_2^2 = \dots = \sigma_n^2 = \sigma^2$$

# Homoskedastyczność

Konsekwencje niespełnienia założenia dotyczącego homoskedastyczności składnika losowego:

- Estymator MNK pozostaje nieobciążony i zgodny, ale nie jest najefektywniejszy.
- Oszacowania wariancji estymatorów są obciążone.

W związku z powyższym w przypadku występowania heteroskedastyczności testy istotności parametrów mogą zwracać błędne wyniki.

# Heteroskedastyczność - testy

Testowanie występowania heteroskedastyczności:

- Test Goldfelda-Quandta – stosowany, gdy podejrzewa się, że wariancja składników losowych zależy od jednej ze zmiennych objaśniających  $X$ .
- Test Breuscha – Pagana (ogólniejszy niż test Goldfelda-Quandta) – służy do zbadania przypuszczenia, że wariancje składników losowych zależą od kilku zmiennych objaśniających.
- Test White'a (podobny do testu Breuscha – Pagana) – w teście tym jako czynniki wpływające na wariancję składnika losowego rozważane są zmienne objaśniające, ich potęgi oraz iloczyny.

# Heteroskedastyczność – testy w R

## ➤ Test Goldfelda-Quandta

```
library(lmtest)
gqtest(model,
        alternative = "two.sided",
        order.by = ~ nazwa_zmiennej_X)
```

## ➤ Test Breuscha – Pagana

```
library(lmtest)
bptest(model)
```

## ➤ Test White'a (w przypadku dwóch zmiennych objaśniających: $x_1$ , $x_2$ )

```
library(lmtest)
bptest(model, ~ x1 + I(x1^2) + x2 + I(x2^2) + x1:x2)
```



# Rozwiązania problemu

W przypadku, gdy składniki losowe są heteroskedastyczne można zastosować:

- Przekształcenie zmiennych (np. logarytmowanie),
- Ważoną metodę najmniejszych kwadratów (WMNK),
- Odporne błędy standardowe (robust standard errors, heteroskedasticity-consistent standard errors).

# Ważona metoda najmniejszych kwadratów

Jeśli w modelu występuje tylko heteroskedastyczność składnika losowego (bez autokorelacji) to do estymacji parametrów modelu można wykorzystać ważoną metodę najmniejszych kwadratów. Polega ona na przypisaniu poszczególnym obserwacjom odpowiednich wag  $\omega_i$ , których celem jest zrównoważenie wariancji czynnika losowego.

Początkowy model:  $y_i = \beta_0 + \beta_1 x_{1i} + \dots + \beta_k x_{ki} + u_i$

$$u_i = \omega_i \cdot \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2), \quad u_i \sim N(0, \omega_i^2 \sigma^2)$$

Przekształcenie zmiennych:  $y_i^* = \frac{y_i}{\omega_i}, x_{1i}^* = \frac{x_{1i}}{\omega_i}, \dots, x_{2i}^* = \frac{x_{2i}}{\omega_i}$

Budowa nowego modelu na zmiennych  $y_i^*, x_{1i}^*, \dots, x_{2i}^*$

# Ważona metoda najmniejszych kwadratów

Problem: w jaki sposób uzyskać wagi  $\omega_i$ ?

Możliwe rozwiązania:

➤ Wykorzystanie pomocniczej regresji opisującej logarytm z podniesionych do kwadratu reszt z modelu MNK. Kolejne kroki:

1) Estymacja parametrów modelu  $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$  za pomocą MNK

2) Wyznaczenie  $\ln(\varepsilon_i^2)$ , gdzie  $\varepsilon_i$  to reszty z modelu z kroku 1

3) Estymacja parametrów modelu  $\ln(\varepsilon_i^2) = \alpha_0 + \alpha_1 x_{1i} + \dots + \alpha_k x_{ki} + v_i$

4) Wyznaczenie  $\widehat{\ln(\varepsilon_i^2)}$

5) Obliczenie wag:  $\omega_i = \sqrt{\exp(\widehat{\ln(\varepsilon_i^2)})}$

6) Wykorzystanie  $\omega_i$  do przekształcenia zmiennych

# Ważona metoda najmniejszych kwadratów

Problem: w jaki sposób uzyskać wagi  $\omega_i$ ?

Możliwe rozwiązania:

- Jeśli wiadomo, że  $j$ -ta zmienna objaśniająca powoduje zmiany w wariancji składnika losowego wprost proporcjonalnie do swojej wartości, to można wykorzystać ją do wyznaczenia wag, np.:

$$\omega_i = \sqrt{x_{ji}}$$

Powyższe sposoby eliminacji problemu heteroskedastyczności nie zawsze są skuteczne. WMNK opiera się na założeniu, że znane są dokładne wielkości wag. W praktyce określenie wag może być jednak dość trudne.

# Przykład w R

Symulacja następującego modelu:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + u_i$$

$$u_i = i \cdot \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2), \text{ czyli } u_i \sim N(0, i^2 \cdot \sigma^2)$$

Utworzenie danych:

```
N <- 200
beta_vec <- c(20, 2, -4)
x1 <- seq(from = 0, to = 5, length.out = N)
x2 <- sample(seq(from = 3, to = 17, length.out = 80), size = N, replace = TRUE)
e <- rnorm(mean = 0, sd = 1:N, n = N)

x <- cbind(1, x1, x2)
y <- x %*% beta_vec + e
dane <- data.frame(y, x1, x2)
```

	y	x1	x2
1	-32.6209313	0.00000000	13.278481
2	-28.7772273	0.02512563	12.215190
3	7.7276732	0.05025126	3.886076
4	-28.3785107	0.07537688	13.278481
5	-2.6475236	0.10050251	7.075949
6	5.7750928	0.12562814	3.354430
7	2.9075944	0.15075377	4.949367
8	-25.4698920	0.17587940	11.329114
9	-9.2448638	0.20100503	8.139241
10	10.4712614	0.22613065	10.000000

# Przykład w R

Estymacja parametrów modelu:  $y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + u_i$

```
call:  
lm(formula = y ~ ., data = data_mat)
```




```
Residuals:  
      Min       1Q   Median       3Q      Max  
-455.63  -47.93   -1.89   48.91  316.90
```

```
Coefficients:  
              Estimate Std. Error t value Pr(>|t|)  
(Intercept)    23.490     26.030   0.902   0.368  
x1             -6.869      5.617  -1.223   0.223  
x2             -3.289      2.106  -1.561   0.120
```

```
Residual standard error: 115 on 197 degrees of freedom  
Multiple R-squared: 0.02078, Adjusted R-squared: 0.01084  
F-statistic: 2.09 on 2 and 197 DF, p-value: 0.1264
```

# Przykład w R

## Wykresy reszt z modelu



# Przykład w R

Testy na heteroskedastyczność – test Goldfelda-Quandt:

➤ Dwa warianty: `order.by = ~ x1` oraz `order.by = ~ x2`

Goldfeld-Quandt test

```
data: model_mnk  
GQ = 8.9024, df1 = 97, df2 = 97, p-value < 2.2e-16  
alternative hypothesis: variance changes from segment 1 to 2
```

Goldfeld-Quandt test

```
data: model_mnk  
GQ = 1.06, df1 = 97, df2 = 97, p-value = 0.7747  
alternative hypothesis: variance changes from segment 1 to 2
```



# Przykład w R

## Testy na heteroskedastyczność – test Breuscha – Pagana

studentized Breusch-Pagan test

```
data: model_mnk  
BP = 35.627, df = 2, p-value = 1.835e-08
```

## Testy na heteroskedastyczność – test White'a

studentized Breusch-Pagan test

```
data: model_mnk  
BP = 37.205, df = 5, p-value = 5.448e-07
```

Wniosek: założenie dotyczące homoskedastyczności składnika losowego nie jest spełnione

# Przykład w R

Wykorzystanie ważonej metody najmniejszych kwadratów

- Wersja I: wyznaczenie wag na podstawie dodatkowej regresji opisującej logarytm z podniesionych do kwadratu reszt z modelu MNK
- Wersja II: wykorzystanie kolejnych liczb całkowitych jako wagi, czyli  $\omega_i = i$

Znając wagi nie trzeba ręcznie przekształcać każdej zmiennej z osobna. WMNK można przeprowadzić dodając argument *weights* w funkcji *lm()*:

```
lm(y~., data = dane, weights = 1/wagi)
```

# Przykład w R

Ważne: funkcja `lm()` mnoży zmienne w regresji razy pierwiastki kwadratowe z podanych wag!

W związku z tym jeśli chce się pomnożyć zmienne w modelu razy  $\frac{1}{\sqrt{x_{ji}}}$  to w funkcji `lm()` należy przypisać do argumentu *weights* wartości  $\frac{1}{x_{ji}}$  (wagi podniesione do kwadratu).

# Przykład w R

## Wersja I (budowa dodatkowego modelu):

- 1) Estymacja parametrów modelu  $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$  za pomocą MNK
- 2) Wyznaczenie  $\ln(\varepsilon_i^2)$ , gdzie  $\varepsilon_i$  to reszty z modelu z kroku 1
- 3) Estymacja parametrów modelu  $\ln(\varepsilon_i^2) = \alpha_0 + \alpha_1 x_{1i} + \dots + \alpha_k x_{ki} + v_i$
- 4) Wyznaczenie  $\widehat{\ln(\varepsilon_i^2)}$
- 5) Obliczenie wag:  $\omega_i = \sqrt{\exp(\widehat{\ln(\varepsilon_i^2)})}$
- 6) Wykorzystanie  $\omega_i$  do przekształcenia zmiennych

```
log_e2 = log(model_mnk$residuals^2)
resid_model <- lm(log_e2 ~ x1 + x2, data = data_mat)
w <- exp(resid_model$fitted.values)
model_wmnk <- lm(y ~ x1 + x2, data = data_mat, weights = 1 / w)
```

# Przykład w R

## Wersja I – wyniki:

```
call:
lm(formula = y ~ x1 + x2, data = data_mat, weights = 1/w)

Weighted Residuals:
    Min       1Q   Median       3Q      Max
-6.1017 -1.0841 -0.0411  1.1737  6.6646

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   20.459      10.259   1.994  0.04751 *
x1            -4.621       4.052  -1.140  0.25549
x2            -3.233       1.001  -3.228  0.00146 **
---
Signif. codes:
  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.012 on 197 degrees of freedom
Multiple R-squared:  0.05682,    Adjusted R-squared:  0.04724
F-statistic: 5.934 on 2 and 197 DF,  p-value: 0.003145
```

# Przykład w R

Chcąc przedstawić wykres reszt z nowo powstałego modelu konieczne jest dokonanie pewnych przekształceń.

Model uwzględniający heteroskedastyczność:  $\mathbf{Y}^* = \mathbf{X}^* \beta + \varepsilon^*$

Reszty z nowego modelu:  $\hat{\varepsilon}_{WMNK}^* = \mathbf{Y}^* - \mathbf{X}^* \hat{\beta}_{WMNK}$

W większości programów przy wykorzystywaniu gotowych funkcji do estymacji WMNK reszty obliczane są na podstawie wzoru:

$$\hat{\varepsilon}_{WMNK} = \mathbf{Y} - \mathbf{X} \hat{\beta}_{WMNK}$$

# Przykład w R

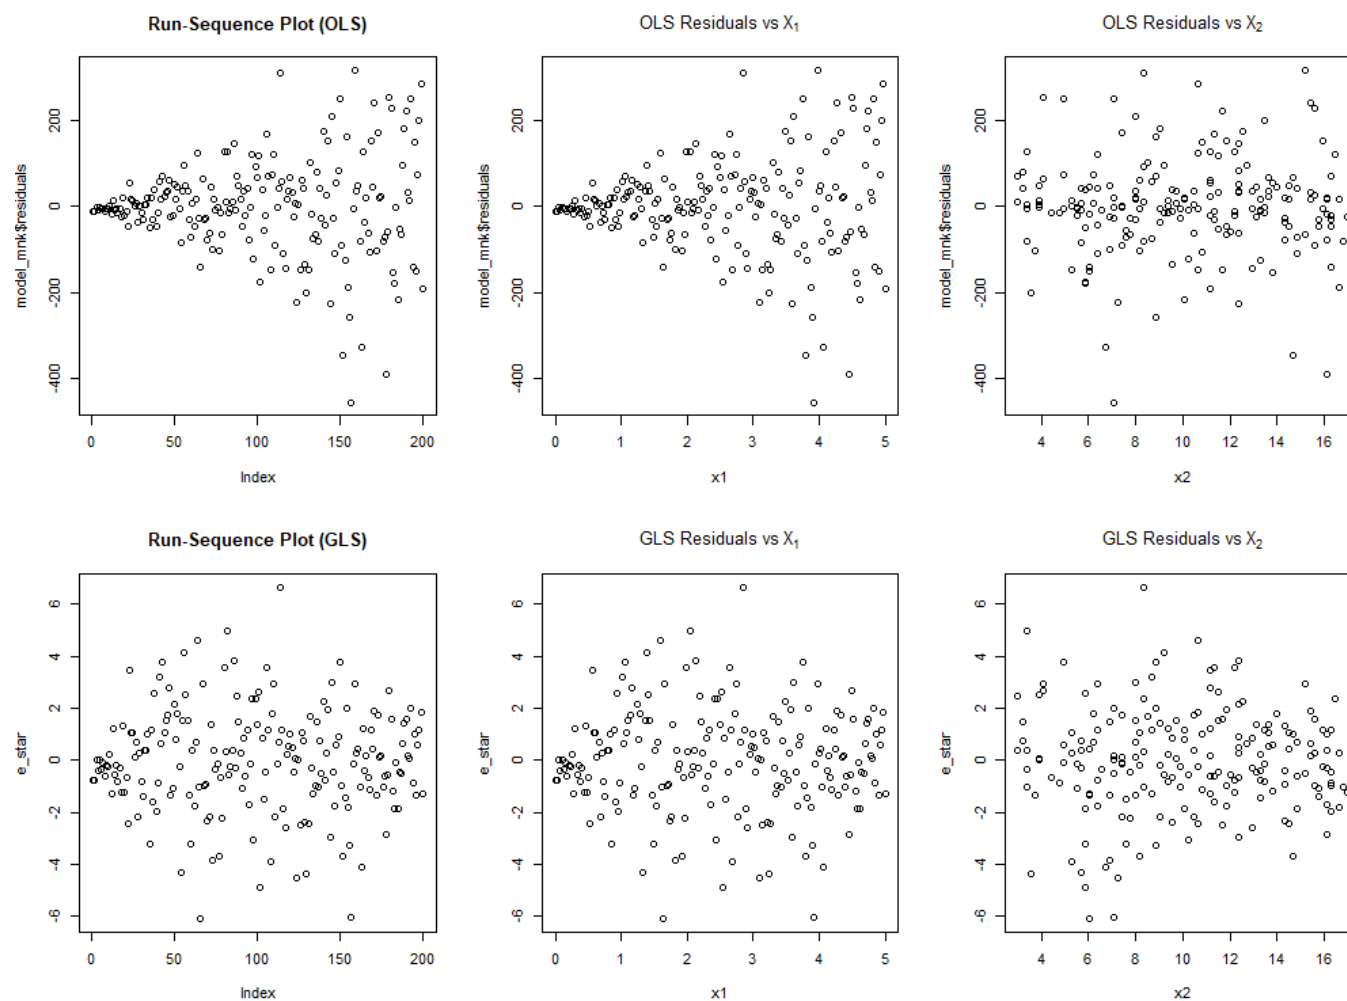
Chcąc ocenić na podstawie wykresów reszt, czy w modelu nadal występuje heteroskedastyczność należy wykorzystać  $\hat{\varepsilon}_{WMNK}^*$ :

$$\begin{aligned}\hat{\varepsilon}_{WMNK}^* &= \mathbf{Y}^* - \mathbf{X}^* \hat{\beta}_{WMNK} = \mathbf{Y} \frac{1}{\omega_i} - \mathbf{X} \frac{1}{\omega_i} \hat{\beta}_{WMNK} = \\ &= \frac{1}{\omega_i} (\mathbf{Y} - \mathbf{X} \hat{\beta}_{WMNK}) = \frac{1}{\omega_i} \hat{\varepsilon}_{WMNK}\end{aligned}$$

Zapis w kodzie:

```
e_star <- (1 / sqrt(w)) * model_wmnk$residuals
```

# Przykład w R





# Przykład w R

Wersja II (wykorzystanie wag:  $\omega_i = i$ ) - wyniki:

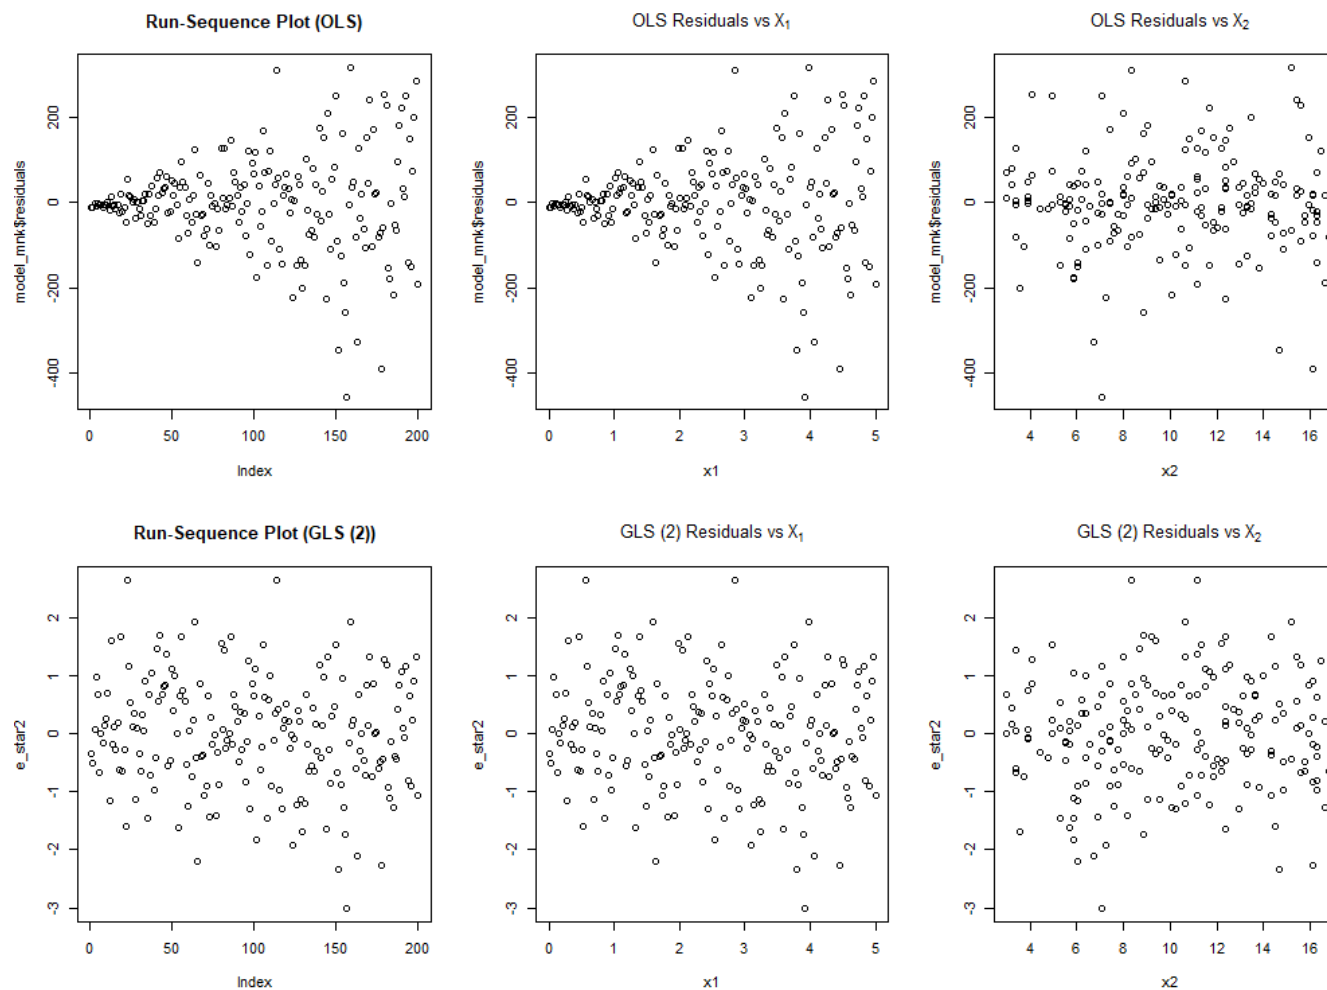
```
call:
lm(formula = y ~ x1 + x2, data = data_mat, weights = 1/(1:N)^2)

Weighted Residuals:
      Min       1Q   Median       3Q      Max
-3.01335 -0.62702  0.01508  0.66931  2.66602

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  24.0172     3.1892    7.531 1.77e-12 ***
x1          -0.8305     2.9402   -0.282  0.778
x2          -4.2399     0.2587  -16.387 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.9714 on 197 degrees of freedom
Multiple R-squared:  0.5837,    Adjusted R-squared:  0.5795
F-statistic: 138.1 on 2 and 197 DF,  p-value: < 2.2e-16
```

# Przykład w R



# Przykład w R

Chcąc przetestować, czy reszty z modelu WMNK są homoskedastyczne należy skorzystać z testu Breuscha – Pagana zaimplementowanego w pakiecie **car** (funkcja **ncvTest()**).

Funkcja **ncvTest()** rozróżnia, czy w modelu uwzględniono wagi.

```
> ncvTest(model_mnk, var.formula = ~ x1 + x2)
Non-constant Variance Score Test
Variance formula: ~ x1 + x2
Chisquare = 73.83468, Df = 2, p = < 2.22e-16
> ncvTest(model_wmnk, var.formula = ~ x1 + x2)
Non-constant Variance Score Test
Variance formula: ~ x1 + x2
Chisquare = 10.9345, Df = 2, p = 0.0042228
> ncvTest(model_wmnk2, var.formula = ~ x1 + x2)
Non-constant Variance Score Test
Variance formula: ~ x1 + x2
Chisquare = 0.696991, Df = 2, p = 0.70575
```