

AGH

AKADEMIA GÓRNICZO-HUTNICZA IM. STANISŁAWA STASZICA W KRAKOWIE

Wydział Zarządzania

Projekt zaliczeniowy

Budowa modelu ekonometrycznego

Badanie czynników wpływających na cenę telefonu

Autorzy:
Kierunek studiów:

Antoni Kois, Filip Mazur
Informatyka i Ekonometria

Kraków, 2025

Dane – źródło i opis	4
Źródło	4
Opis	4
Podstawowe statystyki zmiennych opisujących	4
Analiza współczynników korelacji pomiędzy zmiennym	5
Przygotowanie danych	6
Odrzucenie pierwszych zmiennych oraz zmiana formy danych	6
Zamiana danych “Yes”/”No” na zmienne zero-jedynkowe	6
Usunięcie wartości odstających	6
Budowa pierwszego modelu	7
Dobór pierwszych zmiennych za pomocą metody Hellwiga	7
Analiza przeprowadzonych testów i statystyk dla modelu pierwszego	8
Współczynnik determinacji	8
Podstawowe statystyki reszt	9
Test Normalności Shapiro-Wilka dla reszt	10
Test Kołmogorowa-Smirnowa dla rozkładu normalnego reszt	11
Test Jarque-Bera dla reszt	11
Test Breuscha-Pagana na badanie heteroskedastyczności	12
Test White'a na badanie heteroskedastyczności	12
Test VIF na badanie współliniowości	12
Test Chowa do badania strukturalnych zmian w modelu regresji	13
Założenia testu:	13
Test Ramsey RESET (Regression Specification Error Test)	14
Główne zastosowania:	14
Test liczby serii (Runs Test)	15
Test istotności parametrów – t-Studenta	15
Zastosowanie metod naprawczych	16
Usunięcie nieistotnych zmiennych na podstawie testu t-studenta	16
Finalne testy po zastosowaniu metod naprawczych	18
Podstawowe statystyki reszt	18
Test Normalności Shapiro-Wilka dla reszt	18
Test Kołmogorowa-Smirnowa dla rozkładu normalnego reszt	18
Test Jarque-Bera dla reszt	18
Test Breuscha-Pagana na badanie heteroskedastyczności	19
Test White'a na badanie heteroskedastyczności	19
Test VIF na badanie współliniowości	19
Test Chowa do badania strukturalnych zmian w modelu regresji	19
Test Ramsey RESET (Regression Specification Error Test)	19
Test liczby serii (Runs Test)	20

Ocena modelu	20
Wzór finalnego modelu	20
Statystyki finalnego modelu:	20
Analiza finalnego modelu:	20
Prognoza punktowa i wyznaczenie względnego błędu prognozy EX POST	22
MAPE (Mean Absolute Percentage Error): 26.25%	22
ME (Mean Error): 161.8729	22
MAE (Mean Absolute Error): 316.54	22
RMSE (Root Mean Squared Error): 472.80	22
Najmniejszy błąd względny: 0.05% (obserwacja 135)	22
Podsumowanie	22

Dane – źródło i opis

Źródło

Dane zawierające ceny laptopów oraz potencjalne zmienne mające wpływ na cenę. Zostały one pobrane ze strony kaggle.com. Podzieliliśmy je na dwa zbiory, "train" do budowy modelu oraz "test" do testowania stworzonego modelu. Dane do budowy modelu zawierają 1000 wierszy, natomiast do testowania 200+ wierszy

[Link do źródła danych](#)

Opis

- **Company** - Marka (firma) laptopa
- **TypeName** - Typ laptopa (Notebook, Ultrabook, Gaming itp.)
- **Inches** - Przekątna ekranu (cale)
- **Ram** - Pamięć RAM (GB)
- **OS** - System operacyjny
- **Weight** - Masa laptopa (kg)
- **Price_euros** - Cena laptopa (euro) – zmienna docelowa
- **Screen** - Rozdzielczość/definicja ekranu (Standard, Full HD, 4K Ultra HD, Quad HD+)
- **ScreenW** - Szerokość ekranu w pikselach
- **ScreenH** - Wysokość ekranu w pikselach
- **Touchscreen** - Czy ekran jest dotykowy (0 = nie, 1 = tak)
- **IPSPanel** - Czy ekran ma matrycę IPS (0 = nie, 1 = tak)
- **RetinaDisplay** - Czy ekran to Retina/ekran o bardzo wysokiej gęstości pikseli
- **CPU_company** - Producent procesora (np. Intel, AMD)
- **CPU_freq** - Taktowanie procesora (Hz)
- **PrimaryStorage** - Pojemność głównego dysku (GB)
- **SecondaryStorage** - Pojemność dodatkowego dysku (GB, jeśli występuje)
- **PrimaryStorageType** - Typ głównego dysku (HDD, SSD, Flash Storage, Hybrid)
- **SecondaryStorageType** - Typ dodatkowego dysku (HDD, SSD, Hybrid, None)
- **GPU_company** - Producent karty graficznej


Podstawowe statystyki zmiennych opisujących

Zmienna	Średnia	Odchylenie standardowe	Kurtoza	Skośność	Współczynnik zmienności
Inches	15.0498	1.413668	-0.19787	-0.396643	0.093933
Ram	8.512	4.973791	6.300672	2.074162	0.584327
Weight	2.037788	0.662631	2.516759	1.174558	0.325172
Price_euros	1125.70607	705.380659	5.046084	1.620813	0.626612
ScreenW	1908.702	495.832344	6.758238	2.277741	0.259775
ScreenH	1079.172	285.957952	5.93948	2.17667	0.264979
CPU_freq	2.2868	0.525055	-0.434995	-0.723646	0.229603

PrimaryStorage	444.428	372.158373	3.155327	1.624314	0.837387
SecondaryStorage	179.956	427.102459	4.757773	2.311719	2.373372

Analiza współczynników korelacji pomiędzy zmiennymi

Zmienna	Inches	Ram	Weight	Price_euros	ScreenW	ScreenH	CPU_freq	PrimaryStorage	SecondaryStorage
Inches	1.00000	0.23295	0.82392	0.07079	-0.04676	-0.07043	0.29613	0.26112	0.38299
Ram	0.23295	1.00000	0.38976	0.76340	0.45563	0.44695	0.37303	0.01037	0.39085
Weight	0.82392	0.38976	1.00000	0.21953	-0.00383	-0.02567	0.31324	0.17174	0.47008
Price_euros	0.07079	0.76340	0.21953	1.00000	0.57717	0.57513	0.43245	-0.10604	0.28036
ScreenW	-0.04676	0.45563	-0.00383	0.57717	1.00000	0.99355	0.18731	-0.05033	0.15056
ScreenH	-0.07043	0.44695	-0.02567	0.57513	0.99355	1.00000	0.17671	-0.05732	0.13869
CPU_freq	0.29613	0.37303	0.31324	0.43245	0.18731	0.17671	1.00000	0.05396	0.20782
PrimaryStorage	0.26112	0.01037	0.17174	-0.10604	-0.05033	-0.05732	0.05396	1.00000	-0.23088
SecondaryStorage	0.38299	0.39085	0.47008	0.28036	0.15056	0.13869	0.20782	-0.23088	1.00000



Przygotowanie danych

Odrzucenie pierwszych zmiennych oraz zmiana formy danych

Na wstępie następujące zmienne zostają przez nas odrzucone, bądź zostają do dalszej analizy:

- **Company** - zostawiamy top 6 kategorii co obejmuje 90.30% wierszy (19 kategorii)
- **Product** - zbyt dużo kategorii (618) i zmienna jest mniej istotna
- **TypeName** - mniej istotna zmienna
- **Inches** - pozostawiamy
- **Ram** - pozostawiamy
- **OS** - zostawiamy top 5 kategorii co obejmuje 97.60% wierszy (9 kategorii)
- **Weight** - pozostawiamy
- **Price_euros** - pozostawiamy
- **Screen** - 4 kategorie (wszystkie)
- **ScreenW** - pozostawiamy
- **ScreenH** - pozostawiamy
- **Touchscreen** – pozostawiamy, zmienna 0/1
- **IPSPanel** – pozostawiamy, zmienna 0/1
- **RetinaDisplay** – pozostawiamy, zmienna 0/1
- **CPU_company** - 3 kategorie (wszystkie)
- **CPU_freq** - pozostawiamy
- **CPU_model** - zbyt dużo kategorii (93) i mniej istotne
- **PrimaryStorage** - pozostawiamy
- **SecondaryStorage** - pozostawiamy
- **PrimaryStorageType** - 4 kategorie (wszystkie)
- **SecondaryStorageType** - mała ilość danych posiada uzupełnioną tą wartość, pomijamy
- **GPU_company** - 3 kategorie (wszystkie)
- **GPU_model** - zbyt dużo kategorii i mniej istotne (110)

Zamiana danych "Yes"/"No" na zmienne zero-jedynkowe

Kolumny:

- **Touchscreen**
- **IPSPanel**
- **RetinaDisplay**

Zawierają dane w formacie napisów "Yes"/"No" dlatego, żeby były użyteczne dla naszego modelu zamieniamy je na zmienne zero-jedynkowe, czyli ich wartości będą 0 albo 1. 0 w przypadku gdy zmienna zawierała "No" oraz 1, gdy zawierała "Yes".

Usunięcie wartości odstających

Do ustalenia wartości odstających zostały użyte kwartyle i reguła 1,5*IQR

Zmienna	odstających	%	dolna	górna
ScreenH	331	33.1	1080.0	1080.0
ScreenW	329	32.9	1920.0	1920.0

PrimaryStorage	203	20.3	-128.0	896.0
Ram	171	17.1	-2.0	14.0
SecondaryStorage	164	16.4	0.0	0.0
Weight	33	3.3	0.3	3.5
Inches	30	3.0	11.6	18.0
Price_euros	29	2.9	-713.875	2787.125
CPU_freq	0	0.0	0.45	4.05

Z powodu iż zmienne

- ScreenH
- ScreenW
- PrimaryStorage
- Ram
- SecondaryStorage

zawierają duży odsetek wartości odstających, usuwanie ich podległo wątpliwości. Głębsza analiza danych i informacji doprowadziła do stwierdzenia o nie usuwaniu wartości odstających dla tych kolumn. Stanowsko takie zapadło gdyż np. jak dla **ScreenH** 80 % laptopów ma dokładnie 1080 px wysokości. Każda inna wartość (768, 1440, 1600, ...) jest traktowana jako "odstająca", a bardziej powinno się patrzeć na tę zmienną jako zmienną kategorię. To samo zjawisko można zauważyć dla reszty wymienionych zmiennych.

Odstające wartości zostały usunięte tylko dla

- **Weight**
- **Inches**

W dalszej części budowy modelu być może inne pojedyncze zmienne zostaną poprawione o usunięcie odstających wartości.

Usuając odstające wartości dla **Weight** i **Inches** usunięto 62 obserwacji (6.20 %).

Budowa pierwszego modelu

Dobór pierwszych zmiennych za pomocą metody Hellwiga

Jako zmienne kandydujące uznajemy te, które miały korelację ze zmienną objaśnianą większą lub równą 0,1. Takich zmiennych było 23. Dla każdej z nich obliczono wskaźniki pojemności informacyjnej.

W kolejnym etapie doboru obliczono średnią wartość wskaźników, a następnie wybrano te zmienne, których wartość wskaźnika przekraczała średnią.

Średnia wyniosła 0,0175, a liczba zmiennych o wskaźniku powyżej tej wartości wyniosła 9. Są to:

Zmienna	Wskaźnik pojemności informacyjnej
CPU_freq	0.0983
Touchscreen	0.0598
GPU_company_Nvidia	0.0397
Company_Other	0.0357
IPSPanel	0.0312
CPU_company_Intel	0.0284
OS_No OS	0.0246
SecondaryStorage	0.0194
OS_Linux	0.0186

Podczas dalszej analizy powróciliśmy do etapu doboru zmiennych za pomocą metody Hellwiga i zauważyliśmy potencjalny problem dotyczący wyboru zmiennych zero-jedynkowych. Zauważyliśmy, że z danej zmiennej kategorycznej do budowy modelu kwalifikuje się zwykle tylko jedna zmienna zero-jedynkowa, utworzona na podstawie tej kategorii. Można to interpretować w ten sposób, że zmienna ta przechowuje informację, czy dane wejściowe dla danego przypadku należą do jednej, konkretnej kategorii XXX, czy też do pozostałych.

Wątpliwość tę można było rozwiązać na dwa sposoby:

- Kwalifikować do modelu zmienne, **niezależnie od tego**, czy pochodzą z tej samej kategorii kategorycznej.
- Kwalifikować **całą kategorię** lub ją odrzucać, np. na podstawie średniej lub maksymalnej wartości wskaźników pojemności informacyjnej dla wszystkich zmiennych pochodzących z tej kategorii.

W naszej analizie początkowo przyjęliśmy pierwszy sposób. Wszystkie testy i optymalizacje zostały przeprowadzone w oparciu o tę metodę. Po zapoznaniu się z drugim podejściem, sprawdziliśmy je – jednak wyniki były niespójne: niektóre testy dawały pozytywne efekty, inne negatywne. Po konsultacjach i sugestii zmiany podejścia, zdecydowaliśmy się pominąć te zmienne w procesie doboru Hellwiga, a decyzję o odrzuceniu bądź pozostawieniu zmiennych kategorycznych podjąć na podstawie testów t-Student na istotność pojedynczych parametrów.

Na podstawie wybranych zmiennych zbudowano pierwszy model. Poniżej przedstawiono wzór uzyskanego modelu:

$$Y = -600.0457 + 445.5481 * CPU_freq + 531.8435 * Touchscreen + 179.9755 * GPU_company_Nvidia + 352.3302 * Company_Other + 161.4621 * IPSPanel + 516.2184 * CPU_company_Intel - 411.9843 * OS_No_OS + 0.1153 * SecondaryStorage - 328.5742 * OS_Linux$$

Teraz przystąpimy do analizy testów dla uzyskanego modelu.

Analiza przeprowadzonych testów i statystyk dla modelu pierwszego

Współczynnik determinacji

Współczynnik determinacji pozwala ocenić, w jakim stopniu model objaśnia zmienność zmiennej Y. Współczynnik determinacji wynosi **0.403**. Można z tego

wnioskować, że model jest dość słaby, ponieważ dobrze opisuje zaledwie **40,3%** przypadków.

Współczynnik determinacji skorygowany wynosi natomiast 0.397, czyli jest odrobinę mniejszy czego byśmy się spodziewali, ponieważ liczba obserwacji jest spora w porównaniu do liczby parametrów.

Podstawowe statystyki reszt

Średnia reszt: 0.000000

Mediana reszt: -36.873587


Odchylenie standardowe reszt: 353.0934


Minimum: -1374.1340

Maksimum: 2320.5168


Rozstęp: 3694.6508

Średnia reszt wynosi 0, ponieważ parametry zostały oszacowane za pomocą metody najmniejszych kwadratów (MNK). Na podstawie wartości mediany (-65,93) można przypuszczać, że model ma tendencję do niedoszacowywania (większość reszt jest ujemna). Rozkład reszt jest lekko asymetryczny, co można również zaobserwować na wykresie reszt. Na podstawie odchylenia standardowego można stwierdzić, że model przeciętnie myli się o około 504 jednostki.






Na wykresie reszt można również zauważyć obecność wartości odstających po prawej stronie. Potwierdza to histogram, który dodatkowo pokazuje, dlaczego rozkład reszt odbiega od normalności, co zostanie potwierdzone w kolejnym teście.



Wykres pudełkowy także nam potwierdza, że istnieją wartości odstające w zbiorze reszt.



Test Normalności Shapiro-Wilka dla reszt

Test Shapiro–Wilka służy do sprawdzania, czy dana zmienna ma rozkład normalny. W tym przypadku test ten wykorzystujemy do oceny normalności reszt modelu. Jest to jeden z najczęściej stosowanych testów statystycznych do weryfikacji, czy dane pochodzą z rozkładu normalnego.

H0: Dane pochodzą z rozkładu normalnego.

H1: Dane nie pochodzą z rozkładu normalnego.

Jeśli **$W < W_{krytyczna}$** (z tablic), to odrzucamy H0

Obliczona statystyka W: 0.9304

P-value: 0.0000

Odrzucamy hipotezę o normalności ($\alpha=0.05$)

Test Kołmogorowa-Smirnowa dla rozkładu normalnego reszt

Test ten służy do sprawdzania zgodności rozkładu empirycznego z rozkładem teoretycznym, najczęściej:

- z rozkładem normalnym (jeśli dysponujemy danymi o znanych parametrach średniej i odchylenia standardowego),
- lub do porównania dwóch rozkładów empirycznych (na podstawie dwóch próbek danych).

Hipotezy testowe formułuje się następująco:

H0: Rozkład zmiennej jest zgodny z rozkładem teoretycznym, w tym przypadku z rozkładem normalnym.

H1: Rozkład zmiennej różni się od rozkładu teoretycznego.

Jeśli statystyka testowa **D przekracza wartość krytyczną $D_{krytyczna}$** (odczytaną z odpowiednich tablic), wówczas odrzucamy hipotezę zerową.

W niniejszej analizie test ten został zastosowany do sprawdzenia normalności rozkładu reszt. Należy jednak zauważyć, że ma on zazwyczaj mniejszą moc niż test Shapiro–Wilka, szczególnie w przypadku małych prób.

Obliczona statystyka: 0.0817

P-value: 0.0000

Odrzucamy hipotezę o normalności ($\alpha=0.05$)

Test Jarque-Bera dla reszt

Test Jarque’a-Bery jest testem statystycznym służącym do oceny, czy dana zmienna ma rozkład normalny. Opiera się on na analizie dwóch momentów wyższych rzędu: **skośności (skewness)** i **kurtozy (kurtosis)**. Test sprawdza, czy te dwa parametry różnią się istotnie od wartości teoretycznych dla rozkładu normalnego, odpowiednio 0 (dla skośności) i 3 (dla kurtozy).

Hipoteza zerowa: Dane pochodzą z rozkładu normalnego.

Hipoteza alternatywna: Dane nie pochodzą z rozkładu normalnego.

Obliczona statystyka: 1257.9988

P-value: 0.0000

Odrzucamy hipotezę o normalności ($\alpha=0.05$)

Test Breuscha-Pagana na badanie heteroskedastyczności

Test Breuscha–Pagana służy do wykrywania heteroskedastyczności w modelu regresji liniowej, czyli oceny, czy wariancja składnika losowego (reszt) jest stała (homoskedastyczność), czy zmienia się w zależności od wartości zmiennych objaśniających (heteroskedastyczność).

H0: Wariancja składnika losowego jest stała (czyli brak heteroskedastyczności, czyli homoskedastyczność)

H1: Wariancja składnika losowego nie jest stała (czyli występuje heteroskedastyczność)

Odrzucamy H0, gdy $LM > \chi^2(\alpha)$ krytyczne

Statystyka LM: 163.4072

p-value (LM): 0.0000

Statystyka F: 8.3833

p-value (F): 0.0000

Odrzucamy hipotezę o homoskedastyczności ($\alpha=0.05$),

Występuje heteroskedastyczność

Test White'a na badanie heteroskedastyczności

Test White'a, podobnie jak test Breuscha–Pagana, służy do wykrywania heteroskedastyczności w modelu regresji liniowej. Jest jednak bardziej ogólny, ponieważ nie wymaga przyjęcia konkretnej formy zależności wariancji składnika losowego od zmiennych objaśniających. Umożliwia wykrycie zarówno liniowej, jak i nieliniowej heteroskedastyczności, co czyni go bardziej elastycznym narzędziem diagnostycznym.

H0: Brak heteroskedastyczności, czyli wariancja reszt jest stała.

H1: Występuje heteroskedastyczność (wariancja składnika losowego nie jest stała).

Statystyka LM: 470.3533

P-value (LM): 0.0000

Statystyka F: 5.0354

P-value (F): 0.0000

Odrzucamy hipotezę o homoskedastyczności ($\alpha=0.05$),

Występuje heteroskedastyczność

Test VIF na badanie współliniowości

VIF to test do **badania współliniowości (kolinearności)** między zmiennymi objaśniającymi w modelu regresji liniowej. **Współliniowości** występuje, gdy **jedna zmienna objaśniająca** jest silnie skorelowana z **inną lub kilkoma innymi**.

Powoduje, że:

- estymatory OLS są **niestabilne**
- **rośnie wariancja** estymatorów
- trudniej interpretować wyniki i testować istotność.

Ogólnie przyjmuje się, że wartości VIF przekraczające 10 mogą świadczyć o problemie współliniowości wymagającym uwagi. Nie oznacza to jednak od razu, że te zmienne mają zostać usunięte z modelu.

W celu zbadania współliniowości oblicza się statystykę VIF, a następnie interpretuje:

Wartość VIF	Interpretacja
≈ 1	Brak współliniowości
$1 < VIF < 5$	Umiarkowana współliniowość, nie stanowi dużego problemu
≥ 5	Wysoka współliniowość
≥ 10	Bardzo wysoka współliniowość, poważny problem, wymaga zastosowania zm

Po przeprowadzeniu testu otrzymujemy że tylko 8 zmiennych ma VIF na poziomie wyższym niż 10. Zdecydowana większość spełnia założenie o braku współliniowości. Warto też nadmienić iż **VIF > 10 nie oznacza automatycznie, że trzeba usunąć zmienną z modelu**. To spostrzeżenie przyda się w dalszej analizie, gdzie nie będziemy się pozbywać wszystkich zmiennych z VIF > 10.

Kiedy nie usuwać, mimo $VIF > 10$?:

- Gdy zmienna jest istotna statystycznie (p-wartość niska).
- Gdy ma sens interpretacyjny i wpływa pozytywnie na dopasowanie modelu.
- Gdy współliniowość jest nieunikniona (np. dane demograficzne, sezonowość).

Test Chowa do badania strukturalnych zmian w modelu regresji

Test Chowa służy do sprawdzenia, czy **nastąpiła zmiana strukturalna** w danych, czyli czy zależność między zmiennymi w modelu regresji różni się w dwóch (lub więcej) grupach obserwacji. Najczęściej wykorzystywany jest w analizie szeregów czasowych do badania, czy po pewnym punkcie w czasie struktura modelu ulega zmianie.

Test Chowa sprawdza czy parametry regresji w dwóch grupach (lub okresach) są statystycznie takie same

Założenia testu:

- model regresji liniowej w obu grupach ma tę samą strukturę (te same zmienne),
- dane w każdej z grup są niezależne i spełniają założenia klasycznego modelu regresji liniowej,
- punkt podziału danych (na dwie grupy) jest znany z góry.

H₀: brak zmiany strukturalnej – parametry modelu są takie same w obu grupach.

H₁: występuje zmiana strukturalna – przynajmniej jeden parametr różni się między grupami.

W naszym wypadku mamy podział na dwie grupy po 469 obserwacji.

Wyniki:

RSS (model pełny): 116820406.9108

RSS (podpróba 1): 43501387.2973

RSS (podpróba 2): 65801687.4971

RSS (podpróby razem): 109303074.7944

Wartość krytyczna $F(24, 890)$ przy $\alpha=0.05$: 1.5296

$F(k, n-2*k)$ gdzie k - liczba parametrów łącznie ze stałą

P-value: 0.0001

Wniosek:

Odrzucamy H_0 przy $\alpha=0.05$

Parametry modelu nie są stabilne - występuje przełamanie strukturalne

Test Ramseya RESET (Regression Specification Error Test)

Test Ramseya RESET służy do **sprawdzenia poprawności specyfikacji modelu regresji liniowej**, czyli czy model został dobrze zbudowany – czy nie pominięto istotnych zmiennych, czy model ma właściwą postać funkcjonalną, itp.

RESET nie wskazuje konkretnego problemu, ale sygnalizuje, że model może być źle określony (np. brakuje zmiennej, niewłaściwa forma nieliniowości itp.).

Główne zastosowania:

- Wykrycie pominiętych zmiennych,
- Sprawdzenie, czy zależność jest poprawnie modelowana (np. czy nie powinna być nieliniowa),
- Ogólna kontrola poprawności specyfikacji modelu.

H0: model jest poprawnie określony – brak błędów specyfikacji.

H1: model jest źle określony – istnieją błędy specyfikacji.

Wyniki:

RSS (resztowa suma kwadratów) dla modelu ograniczonego (oryginalnego) i nieograniczonego (rozszerzonego):

RSS (model ograniczony): 116820406.9108

RSS (model nieograniczony): 110189367.4303

Różnica RSS: 6631039.4805

Statystyka F: 27.4414

Wartość krytyczna $F(2, 912)$ przy $\alpha=0.05$: 3.0056

$F(num_added, n-k-num_added)$ gdzie num_added - liczba zmiennych dodanych, a k to liczba parametrów w oryginalnym modelu

P-value: 0.0000

Odrzucamy H_0 przy $\alpha=0.05$

Postać analityczna modelu jest nieprawidłowa

Test liczby serii (Runs Test)

Test liczby serii (test serii, runs test) to nieparametryczny test statystyczny używany do sprawdzenia, czy elementy w sekwencji (ciągu) są ułożone losowo.

Najczęściej stosuje się go do:

- sprawdzenia **losowości reszt w regresji** (czy są niezależne),
- analizy szeregu czasowego (czy dane są losowe),
- oceny wzorców w danych binarnych (np. sukces/porażka, 0/1, dodatnia/ujemna reszta).

Pojęcia:

- **Seria (run)** to ciąg **kolejnych** takich samych wartości (np. same plusy lub same minusy), który jest ograniczony przez wartość przeciwną,
- Przykład: w ciągu + + - - + - - mamy 5 serii: ++, --, +, -, --

H0: dane są losowe (liczba serii zgodna z oczekiwaniami losowości).

H1: dane nie są losowe (za mało lub za dużo serii).

Wyniki:

Liczba serii: 482

Oczekiwana liczba serii: 470

Statystyka Z: 0.7514

Wartość krytyczna Z przy $\alpha=0.05$: ± 1.9600

P-value (test dwustronny): 0.4524

Rozkład reszt jest zadowalający, reszty są rozmieszczone losowo

Test istotności parametrów – t-Studenta

Test **t-Studenta** służy do sprawdzania, czy współczynniki regresji liniowej są statystycznie istotne, czyli czy wybrana zmienna objaśniająca ma rzeczywisty wpływ na zmienną zależną w populacji.

H0: zmienna nie wpływa istotnie na Y, czyli zmienna nie jest istotna

H1: zmienna ma istotny wpływ na Y, czyli zmienna jest istotna

Znaleziono 8 nieistotnych zmiennych ($p > 0.05$):

	Współczynnik regresji	$P > t $
Screen_Quad HD+	-111.294293	0.342630
OS_Windows 10	-131.241037	0.256408
OS_Other	139.448984	0.302402
Screen_Standard	314.361162	0.086016
PrimaryStorageType_HDD	-16.360498	0.823765
PrimaryStorageType_Hybrid	-34.278322	0.897211
Screen_Full HD	219.488770	0.152111
OS_macOS	-25.154824	0.875151

Zastosowanie metod naprawczych

Usunięcie nieistotnych zmiennych na podstawie testu t-studenta


Usuujemy zmienne, które wcześniej zostały uznane za nieistotne

Próba budowy modelu WMNK

W kodzie mamy zdefiniowaną funkcję `build_weighted_model`, której celem jest estymacja ważonego modelu regresji liniowej (WLS – Weighted Least Squares) w celu uwzględnienia problemu heteroskedastyczności w danych. Na początku do macierzy zmiennych objaśniających dodawany jest wyraz wolny, a dane są przekształcane do postaci ramki danych. Na podstawie modelu OLS (Ordinary Least Squares) obliczane są reszty, które zostają podniesione do kwadratu i zamienione na wagi jako odwrotność wariancji reszt (dodając małą stałą zapobiegającą dzieleniu przez zero). Następnie funkcja estymuje właściwy model ważony (WLS), wykorzystując przygotowane wagi. Niestety ta metoda nie przyniosła poprawy jeśli chodzi o heteroskedastyczność.

Transformacja logarytmiczna

Do zmiennych zależnych stosujemy transformację logarytmiczną. Miała na celu ona spowodowanie normalności, co się udało.



Usunięcie zmiennej na podstawie statystyki VIF

Testy na normalność uległy znacznej poprawie, widzimy, że są 3 zmienne (`CPU_company_Intel`, `ScreenW`, `CPU_freq`) z $VIF > 10$, dlatego na początku usuwamy tylko jedną. Resztę zmiennych z $VIF > 10$ pozostawiamy ponieważ: model działa dobrze (R^2 , testy reszt OK) oraz zmienna ma sens merytoryczny.

```
X_data = X_data.drop(columns=["CPU_company_Intel"])
```

Przełamanie strukturalne

Metoda naprawcza służy do uwzględnienia w modelu regresji efektu przełamania strukturalnego, czyli sytuacji, gdy w danych występuje istotna zmiana w pewnym punkcie czasowym lub porządkowym. Najpierw tworzy zmienną wskaźnikową (dummy), która rozdziela obserwacje na dwie grupy: przed i po wskazanym punkcie przełamania. Następnie do macierzy zmiennych objaśniających dodaje nowe kolumny będące iloczynem oryginalnych zmiennych oraz tej zmiennej wskaźnikowej, co pozwala modelowi różnicować wpływ tych zmiennych w obu okresach. Dodatkowo dodaje samą zmienną wskaźnikową jako osobną kolumnę. Dzięki temu model może przyjmować różne współczynniki dla poszczególnych zmiennych w zależności od tego, czy obserwacja znajduje się przed, czy po przełamaniu strukturalnym. Ta metoda przyniosła oczekiwany efekt.

Przed metodą (Test Chowa)	Po metodzie (Test Chowa)
RSS (model pełny): 116820406.9108 RSS (podpróba 1): 43501387.2973 RSS (podpróba 2): 65801687.4971 RSS (podpróby razem): 109303074.7944 Statystyka F: 2.5504 Wartość krytyczna: 1.5296 P-value: 0.0001 Parametry modelu są niestabilne	RSS (model pełny): 82.1940 RSS (podpróba 1): 34.6172 RSS (podpróba 2): 46.1304 RSS (podpróby razem): 80.7476 Statystyka F: 0.5242 Wartość krytyczna: 1.4722 P-value: 0.9841 Parametry modelu są stabilne

Korekta Ramsey RESET

Metoda naprawcza służy do poprawy modelu regresji metodą opartą na teście Ramsey'a RESET, który wykrywa nieliniowości w modelu. Dla wybranych ważnych zmiennych ciągłych (CPU_freq i ScreenW) oblicza ich standaryzowane kwadraty, które dodaje do zbioru danych jako nowe kolumny. Kolejnym krokiem jest wykrycie zmiennych liczbowych o silnie skośnym rozkładzie, przy czym pomijane są zmienne binarne. Dla tych zmiennych tworzona jest transformacja logarytmiczna, a oryginalne kolumny są usuwane, co pomaga w normalizacji rozkładu i stabilizacji wariancji. Dodatkowo tworzone są nowe zmienne będące interakcjami między wybranymi zmiennymi ciągłymi a binarnymi, gdzie zmienna ciągła jest standaryzowana przed mnożeniem. Dzięki temu model może lepiej uchwycić nieliniowe zależności i zmienne współzależności między cechami.

Usunięcie nieistotnych zmiennych

Po wykonaniu na tym etapie testu t-studenta, dostaliśmy informację, że 4 zmienne są nieistotne. Uznaliśmy więc, że należy je usunąć.

Finalne testy po zastosowaniu metod naprawczych

Podstawowe statystyki reszt

Średnia reszt: -0.001057

Mediana reszt: -0.001229

Odchylenie standardowe reszt: 0.2758

Minimum: -0.9363

Maksimum: 0.8639

Rozstęp: 1.8003

Test Normalności Shapiro-Wilka dla reszt

Obliczona statystyka W: 0.9970

P-value: 0.0716

Test Kołmogorowa-Smirnowa dla rozkładu normalnego reszt

Obliczona statystyka: 0.0251

P-value: 0.5883

Test Jarque-Bera dla reszt

Obliczona statystyka: 2.5522

P-value: 0.2791

Wyniki testów Shapiro-Wilka, Kołmogorowa-Smirnowa oraz Jarque-Bera wskazują, że rozkład reszt nie odbiega istotnie od normalnego. Spełnione zostało ważne założenie regresji.

Test Breuscha-Pagana na badanie heteroskedastyczności

Statystyka LM: 117.3412

p-value (LM): 0.0000

Statystyka F: 4.4769

p-value (F): 0.0000

Odrzucamy hipotezę o homoskedastyczności ($\alpha=0.05$),

Test White'a na badanie heteroskedastyczności

Statystyka LM: 455.0344

P-value (LM): 0.0000

Statystyka F: 2.8961

P-value (F): 0.0000

Odrzucamy hipotezę o homoskedastyczności ($\alpha=0.05$),

Test VIF na badanie współliniowości

Po przeprowadzeniu testu otrzymujemy że tylko 7 zmiennych ma VIF na poziomie wyższym niż 10. Jest to mniej niż w pierwotnej wersji. Zdecydowana większość spełnia założenie o braku współliniowości.

Test Chowa do badania strukturalnych zmian w modelu regresji

RSS (model pełny): 71.2443

RSS (podpróba 1): 27.1386

RSS (podpróba 2): 42.8983

RSS (podpróby razem): 70.0369

Statystyka F: 0.5045

Wartość krytyczna: 1.4722

P-value: 0.9883

Parametry modelu są stabilne

Test Ramsey RESET (Regression Specification Error Test)

RSS (resztowa suma kwadratów) dla modelu ograniczonego (oryginalnego) i nieograniczonego (rozszerzonego):

RSS (model ograniczony): 71.2760

RSS (model nieograniczony): 70.9648

Różnica RSS: 0.3113

Statystyka F: 1.9869

Wartość krytyczna: 3.0057

P-value: 0.1377

Postać analityczna jest prawidłowa. Brak przesłanek do odrzucenia hipotezy o prawidłowej formie analitycznej modelu – model nie pomija istotnych zmiennych ani nie zawiera błędnych przekształceń.

Test liczby serii (Runs Test)

Liczba serii: 474

Oczekiwana liczba serii: 470

Statystyka Z: 0.2287

Wartość krytyczna Z przy $\alpha=0.05$: ± 1.9600

P-value (test dwustronny): 0.8191

Rozkład reszt jest zadowalający, reszty są rozmieszczone losowo

Ocena modelu

Wzór finalnego modelu

$$Y = -0.3323 + 0.0932 * Company_Lenovo + -0.1788 * OS_Linux + -0.2871 * OS_No$$
$$OS + 0.3012 * Company_Other + 0.1437 * CPU_freq + 0.1871 * GPU_company_Nvidia + 0.1868 * Company_Dell + 0.1044 * Company_Asus +$$
$$0.1008 * Company_HP + 0.2170 * PrimaryStorageType_SSD + 0.1647 * GPU_company_Intel + 0.1815 * Company_Toshiba + 0.0978 * Company_Lenovo_group2 + 0.0773 * OS_Linux_group2 + 0.0260 * OS_No$$
$$OS_group2 + -0.1557 * Company_Other_group2 + -0.0001 * ScreenW_group2 + 0.1135 * CPU_freq_group2 + 0.1442 * GPU_company_Nvidia_group2 + 0.0781 * Company_Dell_group2 + 0.1854 * Company_HP_group2 + 0.1706 * GPU_company_Intel_group2 + 0.1445 * Company_Toshiba_group2 + -0.0072 * ScreenW_squared + 0.6690 * Ram_log + 0.6586 * ScreenW_log + -0.0668 * Ram_group2_log + 0.0255 * CPU_freq_x_Company_Lenovo + 0.0445 * ScreenW_x_GPU_company_Intel$$

Statystyki finalnego modelu:

R²: 0.9995 (OLS: 0.7781)

Durbin-Watson: 2.0330 (OLS: 2.0520)

Jarque-Bera (JB): 147.8530 (OLS: 2.2810), p-value: 0.0000 (OLS: 0.3200)

Test t-studenta: Wszystkie parametry są istotne

Analiza finalnego modelu:

Bardzo wysoka wartość R² (0.9995) wskazuje, że model nadal niemal idealnie dopasowuje się do danych – niemal cała zmienność w wynikach jest wyjaśniana przez uwzględnione cechy, co potwierdza wysoką jakość predykcji. Nawet uproszczony model (OLS) osiąga R² = 0.7781, co nadal świadczy o dobrym dopasowaniu. W modelu zawarto szeroki zestaw cech – od podstawowych parametrów sprzętowych (jak częstotliwość CPU, producent, typ GPU i dysku), po ich przekształcenia (logarytmy, kwadraty, interakcje), co pozwala modelowi uchwycić złożone, nieliniowe zależności między cechami. Wartość statystyki Durbin-Watsona (~2.03) sugeruje, że reszty modelu nie są autokorelacyjne – nie występuje systematyczny błąd w przewidywaniach. To pozytywny sygnał świadczący o stabilności modelu. Test Jarque-Bera wskazuje, że rozkład reszt odbiega od normalnego (p < 0.05), jednak w praktyce nie powinno to znacząco wpływać na skuteczność predykcyjną modelu – szczególnie przy tak wysokim R².

Parametry modelu (czyli współczynniki przy poszczególnych zmiennych) pokazują, jak każda cecha wpływa na wynik – przy założeniu, że inne zmienne są niezmiennie:

- CPU_freq (0.1437): Wyższa częstotliwość procesora przekłada się na wzrost wartości zmiennej zależnej. Oznacza to, że szybsze procesory są

premiowane w ocenie/wartości laptopów.

- ScreenW_log (0.6586): Większa szerokość ekranu (w skali logarytmicznej) wyraźnie zwiększa wartość, co jest zrozumiałe – większe ekrany to często cecha sprzętów wyższej klasy.
- Ram_log (0.6690): Większa ilość pamięci RAM także znacząco podnosi wartość końcową – zgodne z intuicją oraz oczekiwaniami użytkowników.
- PrimaryStorageType_SSD (0.2170): Laptopy z dyskiem SSD są wyżej oceniane – ze względu na szybkość działania i nowoczesność rozwiązania.
- Company_Dell (0.1868), Company_Toshiba (0.1815), Company_HP (0.1008) – pozytywne współczynniki dla tych firm wskazują, że ich sprzęty są postrzegane jako bardziej wartościowe.
- OS_No OS (-0.2871): Brak systemu operacyjnego istotnie obniża wartość – to zrozumiałe, ponieważ taki sprzęt wymaga dodatkowych działań przed użyciem.
- GPU_company_Nvidia (0.1871), GPU_company_Intel (0.1647): Obecność kart graficznych znanych producentów pozytywnie wpływa na ocenę sprzętu.
-
- CPU_freq_x_Company_Lenovo (0.0255): Wskazuje, że częstotliwość procesora ma szczególnie istotny wpływ na wartość w laptopach Lenovo.
- ScreenW_x_GPU_company_Intel (0.0445): Szerokość ekranu ma dodatkowy pozytywny wpływ w połączeniu z kartami graficznymi Intel.
- ScreenW_squared (-0.0072): Sugeruje malejące korzyści z dalszego zwiększania szerokości ekranu – zbyt duży ekran może być mniej praktyczny lub nieefektywny kosztowo.
- Ram_group2_log (-0.0668): Wskazuje, że wpływ RAM-u w pewnych grupach jest niższy niż w ogólnej populacji – być może wynika to z segmentacji cenowej lub innych czynników.

Wartości dodatnie oznaczają pozytywny wpływ na wynik, ujemne – negatywny.

Prognoza punktowa i wyznaczenie względnego błędu prognozy EX POST

MAPE (Mean Absolute Percentage Error): 26.25%

Średni **względny** błąd prognozy wynosi **26.15%**, co oznacza, że model przeciętnie myli się o ~26% względem rzeczywistej ceny laptopa.

Zakres interpretacji:

- poniżej 10% – bardzo dobrze,
- 10–20% – dobry model,
- 20–30% – umiarkowana jakość (nasz model jest w tym przedziale),
- powyżej 30% – model wymaga poprawy lub dane są bardzo zróżnicowane.

ME (Mean Error): 161.8729

Średni błąd bezwzględny z uwzględnieniem znaku. Dodatnia wartość oznacza, że model ma tendencję do przeszacowywania cen – średnio o 161.88 euro. Może wskazywać na systematyczne przeszacowanie.

MAE (Mean Absolute Error): 316.54

Średni absolutny błąd prognozy w euro. Model przeciętnie myli się o około 316.5 euro w każdej prognozie – bez względu na kierunek (czy zawyżył, czy zaniżył).

RMSE (Root Mean Squared Error): 472.80

Pierwiastek z błędu średniokwadratowego. Ta metryka bardziej karze duże błędy. RMSE większe od MAE sugeruje, że model popełnia pojedyncze, ale znaczne błędy.

Najmniejszy błąd względny: 0.05% (obserwacja 135)

Najmniejszy błąd względny: 0.05% (obserwacja 135)

Rzeczywista cena: 1099 euro

Prognozowana cena: ok. 1099.57 euro

Model bardzo dobrze dopasował prognozę – błąd zaledwie około kilkadziesiąt centów.

Podsumowanie

Model radzi sobie umiarkowanie dobrze. MAPE na poziomie 26.25% oraz MAE na poziomie około 316.5 euro są akceptowalne dla danych rynkowych. Występują jednak przypadki z dużym błędem, które mogą wynikać z nietypowych konfiguracji laptopów. RMSE większe od MAE wskazuje na obecność pojedynczych, ale znaczących odchyleń.